Video Coding for Machine Vision Applications

Στρατίκης Περικλής [1], Καραμπογιάς Παναγιώτης [2]

[1]AM : 2122033, email: pstratikis@uth.gr

[2]AM : 2122111, email: pakarampogias@uth.gr

Περίληψη

Στην παρούσα εργασία παρουσιάζουμε τη διαδικασία, τα πειράματα και τον κώδικα που χρησιμοποιήθηκε για την αξιολόγηση τριών σύγχρονων μοντέλων συμπίεσης εικόνας μέσω της βιβλιοθήκης CompressAI. Εξετάζουμε την απόδοσή τους σε όρους ποιότητας και ρυθμού, αναλύουμε τις διαφορές μεταξύ τους και καταγράφουμε τα αποτελέσματα με πλήρη αναπαραγωγιμότητα.

1. Εισαγωγή

Η κωδικοποίηση βίντεο μετατρέπει τα ακατέργαστα αρχεία βίντεο σε μια μικρότερη, πιο διαχειρίσιμη ψηφιακή μορφή. Εφαρμόζει σύνθετους αλγόριθμους συμπίεσης που εξαλείφουν τα περιττά δεδομένα για να μειώσουν το μέγεθος του αρχείου, διατηρώντας παράλληλα όσο το δυνατόν περισσότερη ποιότητα βίντεο.Η κωδικοποίηση βίντεο διευκολύνει την αποθήκευση, τη μετάδοση και την αναπαραγωγή βίντεο σε διάφορες συσκευές.Δεδομένου ότι εξοικονομεί χώρο διακομιστή, είναι απαραίτητη για την αποθήκευση στο διαδίκτυο και την κοινή χρήση βίντεο.Αφού αναλύσει το περιεχόμενο των καρέ για να προσδιορίσει τη σημασία τους, η συμπίεση βίντεο χρησιμοποιεί αλγόριθμους κωδικοποίησης για να μειώσει το μέγεθος των ψηφιακών αρχείων βίντεο πιθανώς έως και 50%. Εξαλείφει τα μη απαραίτητα καρέ και αναφέρεται σε πανομοιότυπα καρέ αντί να τα αποθηκεύει.[1]

2. Οδηγίες σχετικά με το project

- Στόχος είναι η υποκειμενική οπτική ποιότητα όπως την αντιλαμβάνεται το ανθρώπινο μάτι.
- Προτεραιότητα στην ανθρώπινη όραση: ευκρίνεια, χρώματα, οπτική άνεση.
- Προτεραιότητα στην αλγοριθμική χρήση: πληροφοριακό περιεχόμενο, σταθερή αναπαράσταση χαρακτηριστικών

- Στο project θα συγκρίνουμε το αντίκτυπο που έχουν διαφορετικά μοντέλα κωδικοποίησης βίντεο όσον αφορά το rate-distortion. Θα πάρουμε μετρικές PSNR και MS-SSIM

2.1 Αναπαραγωγιμότητα

- [2] Ορισμός: Η δυνατότητα να τρέξει κάποιος το ίδιο πείραμα χρησιμοποιώντας τον ίδιο κώδικα, δεδομένα και ρυθμίσεις, και να πάρει τα ίδια αποτελέσματα.

- [3] Γιατί είναι σημαντικό: Βοηθά στην αξιοπιστία των αποτελεσμάτων, επιτρέπει σε άλλους ερευνητές να ελέγξουν ή να επεκτείνουν τη δουλειά τους..

- [4] Προκλήσεις: Μη-ντετερμινισμός (random seeds, υλικό, εκδόσεις βιβλιοθηκών) μπορεί να εμποδίζει την αναπαραγωγή.

- [5] Σχετικό έργο / πρότυπα: Το “REFORMS: Reporting Standards for Machine Learning Based Science” προτείνει οδηγίες για αναφορές που ενισχύουν την αναπαραγωγιμότητα.

2.2 Μελέτη Αφαίρεσης

- [6]Ορισμός: Τεχνική στην οποία αφαιρείται συστηματικά ένα ή περισσότερα συστατικά (features, layers, modules) ενός μοντέλου, ώστε να εκτιμηθεί η συμβολή τους στην συνολική απόδοση. Βικιπαίδεια+1

- [7] Σκοπός: Να καταλάβουμε ποια τμήματα του μοντέλου είναι κρίσιμα — αν η απόδοση πέφτει πολύ μετά την αφαίρεση, τότε αυτό το κομμάτι ήταν σημαντικό. California Learning Resource Network

2.3 Δομη Αναφοράς

- Η αναφορά περιλαμβάνει την εισαγωγή, την εκτέλεση , τα δεδομένα και τέλος τα αποτελέσματα και τα συμπεράσματα

2.4 Υποβαθρο

Η κλασική συμπίεση εικόνας και βίντεο βασίζεται σε μια διαδοχική διαδικασία που μειώνει την πλεονάζουσα πληροφορία και περιγράφει την εικόνα με όσο το δυνατόν λιγότερα bits χωρίς υπερβολική απώλεια ποιότητας.

- Παρότι οι σύγχρονοι codecs διαφέρουν αρχιτεκτονικά, το θεμέλιο παραμένει σταθερό εδώ και δεκαετίες: πρόβλεψη, μετασχηματισμός, κβαντοποίηση και κωδικοποίηση εντροπίας.Ο κωδικοποιητής προσπαθεί πρώτα να εκτιμήσει το επόμενο δείγμα ή block με βάση ήδη κωδικοποιημένα δεδομένα.
- Στις εικόνες η πρόβλεψη είναι χωρική (intra prediction). Στόχος είναι να μειωθεί όσο γίνεται η πληροφορία που πρέπει να σταλεί: αντί για την πραγματική τιμή, στέλνεται μόνο το prediction error, που έχει χαμηλότερη εντροπία.Το prediction error μετασχηματίζεται σε έναν χώρο όπου οι συντελεστές συγκεντρώνουν την ενέργεια σε λίγες διαστάσεις. Αυτή η μετατροπή επιτρέπει στον κωδικοποιητή να εντοπίσει ποιες συχνότητες μπορούν να παραλειφθούν ή να περιγραφούν πιο χονδρικά χωρίς μεγάλη οπτική απώλεια.
- Στο στάδιο της κβαντοποίησης χάνονται δεδομένα, αλλά κερδίζεται μεγάλη συμπίεση. Οι συντελεστές του μετασχηματισμού χωρίζονται σε διακριτά επίπεδα, ενώ οι λεπτές διαφορές στρογγυλοποιούνται. Με πιο επιθετική κβαντοποίηση μειώνεται το bitrate αλλά αυξάνεται η παραμόρφωση. Η επιλογή των quantization parameters καθορίζει άμεσα την ισορροπία ποιότητας και μεγέθους.
- Αφού κβαντιστούν, οι συντελεστές κωδικοποιούνται με αλγορίθμους όπως Huffman coding ή arithmetic coding. Έτσι εξασφαλίζεται ότι το τελικό bitstream είναι όσο το δυνατόν πιο συμπιεσμένο χωρίς επιπλέον απώλειες.[8]

Αυτόματοι κωδικοποιητές

- Οι αυτόματοι κωδικοποιητές έχουν γίνει ένα καυτό θέμα έρευνας στη μη επιβλεπόμενη μάθηση λόγω της ικανότητάς τους να μαθαίνουν χαρακτηριστικά δεδομένων και να λειτουργούν ως μέθοδος μείωσης διαστάσεων. Με την ταχεία εξέλιξη των μεθόδων αυτόματου κωδικοποιητή, δεν έχει ακόμη υπάρξει μια ολοκληρωμένη μελέτη που να παρέχει έναν πλήρη χάρτη πορείας για τους αυτόματους κωδικοποιητές τόσο για την τόνωση των τεχνικών βελτιώσεων όσο και για τον προσανατολισμό των αρχάριων ερευνητών στους αυτόματους κωδικοποιητές. [9]

Εντροπία

- Στη θεωρία πληροφοριών , η **εντροπία** μιας τυχαίας μεταβλητής ποσοτικοποιεί το μέσο επίπεδο αβεβαιότητας ή πληροφοριών που σχετίζονται με τις πιθανές καταστάσεις ή τα πιθανά αποτελέσματα της μεταβλητής. Αυτό μετράει την αναμενόμενη ποσότητα πληροφοριών που απαιτούνται για να περιγραφεί η κατάσταση της μεταβλητής, λαμβάνοντας υπόψη την κατανομή των πιθανοτήτων σε όλες τις πιθανές καταστάσεις. Δεδομένης μιας διακριτής τυχαίας μεταβλητής. [10]

- Το CompressAI βασίζεται στο PyTorch και παρέχει: προσαρμοσμένες λειτουργίες, επίπεδα και μοντέλα για συμπίεση δεδομένων που βασίζεται σε βαθιά μάθηση μια μερική μεταφορά της επίσημης βιβλιοθήκης συμπίεσης TensorFlow προ-εκπαιδευμένα μοντέλα συμπίεσης από άκρο σε άκρο για μαθημένη συμπίεση εικόνας σενάρια αξιολόγησης για τη σύγκριση μαθησιακών μοντέλων με κλασικούς κωδικοποιητές συμπίεσης εικόνας/βίντεο Το CompressAI στοχεύει να επιτρέψει σε περισσότερους ερευνητές να συνεισφέρουν στον τομέα της συμπίεσης εικόνας και βίντεο, παρέχοντας πόρους για την έρευνα, την εφαρμογή και την αξιολόγηση κωδικοποιητών συμπίεσης που βασίζονται στη μηχανική μάθηση.[11]

3. Δεδομένα

Χρησιμοποιήθηκαν 24 εικόνες από την συλλογή [Kodak Lossless True Color Image Suite] σε αναλυση 768x512 ή 512x768 σε διαμόρφωση png με βάθος χρώματος 24 bit.

4. Μεθοδολογία και πρωτόκολλα

- Καθώς τα τρια διαφορετικά μοντέλα που χρησιμοποιούμε έχουν διαφορετικά εύρη ποιότητας (π χ [1-9], [1-6], [1-8]) αποφασίσαμε να πειραματιστούμε στο εύρος 1-6 μιάς και έτσι έχουμε καλύτερο μέτρο σύγκρισης
- Τα Δεδομένα που χρησιμοποιήθηκαν για τεστ και σατ 3 μοντελα ειναι οι 24 φωτογραφιες απο το kodak dataset με centercrop 256x256 και 6 επιπεδα ποιοτητας
- Οι εκδόσεις βιβλιοθηκων framework και python που χρησιμοποιήθηκαν είναι οι παρακατω
    1. Python 3.12.6
    2. numpy 1.26.4
    3. pandas 2.3.3
    4. pip 25.3
    5. torch 2.6.0
    6. compressai 1.2.8
    7. matplotlib 3.10.7
    8. pytorch-msssim 1.0.0
    9. pillow 10.4.0
- Τα pretrained models που χρησιμοποιήθηκαν είναι τα
    1. bmshj2018_factorized
    2. mbt 2018
    3. cheng 2020 attn
- Οι μετρικες που υπολογιστηκαν στο προγραμμα ειναι οι εξης

```
img,model,level,bpp,psnr,ms_ssim,enc_time,dec_time,mem
```

- Τα αποτελεσματα των μετρικων αυτων αποθηκευοντε στο results/image_rd_kodak.csv
- Ablation: Αποφασίσαμε να μεταβάλουμε την τιμή του centercrop απο 256 σε 512 μιάς και ήταν ένας σχετικά γρήγορος τρόπος να μελετήσουμε την μεταβολή της συμπεριφοράς των αλγορίθμων όταν η ανάλυση των φωτογραφιών αλλάζει.
- Η αύξηση του crop από 256x256 σε 512x512 οδηγεί σε σημαντικά μεγαλύτερο υπολογιστικό κόστος και κατανάλωση μνήμης, με μικρή έως μέτρια βελτίωση στην ποιότητα των μετρικών (PSNR/MS-SSIM). Οι εικόνες περιέχουν περισσότερη πληροφορία και τα μοντέλα τείνουν να συμπεριφέρονται πιο σταθερά, αλλά ο χρόνος εκτέλεσης αυξάνεται αισθητά.

5. Εφαρμογή

- Οι αλγόριθμοι έτρεξαν σε λάπτοπ lenovo legion που χρησιμοποιούσε Windows 11 και είχε dedicated κάρτα γραφικών nVidia 3050ti, και επεξεργαστή intel core i5 10500H. Όσον αφορά το λογισμικό που χρησιμοποιήσαμε ήταν το εξής, το PyTorch 2.6.0, CompressAI 1.2.8 και Python 3.12.6.
- Οι κώδικες που χρησιμοποιήθηκαν ήταν οι run_image.py και run_plots.py σε Python οι οποίοι καλούνταν απο το run.bat .
- Τα plots δημιουργήθηκαν από το πρόγραμμα run_plots
- **Experimental Setup**
- **Παρακατω ακολουθει το setup των δεδομενων με ορισμο του centercrop CompressAi families, quality levels και δυο συναρτησεις για τον υπολογισμο του bpp και psnr**

```
MODELS = [
    "bmshj2018-factorized",
    "mbt2018",
    "cheng2020-attn"
]
QUALITY_LADDER = [1, 2, 3, 4, 5, 6]
CROP_SIZE = 256
```

```python
def center_crop(img, size):

    w, h = img.size

    left = (w - size) // 2

    top = (h - size) // 2

    return img.crop((left, top, left + size, top + size))

def image_to_tensor(img):

    arr = np.asarray(img).astype(np.float32) / 255.0

    return torch.tensor(arr).permute(2, 0, 1).unsqueeze(0)

def compute_bpp(bitstream_len_bits, H, W):

    return bitstream_len_bits / (H * W)

def compute_psnr(x, x_hat):

    mse = torch.mean((x - x_hat) ** 2).item()

    if mse == 0:

        return float("inf")

    return 10 * math.log10(1.0 / mse)
```

- **Αποτελέσματα**

Το αποτελεσμα του συνολικου κωδικα ειναι ενα csv με τις παρακατω μετρικες

```
img,model,level,bpp,psnr,ms_ssim,enc_time,dec_time,mem
```

Και τα δυο παρακατω plots :

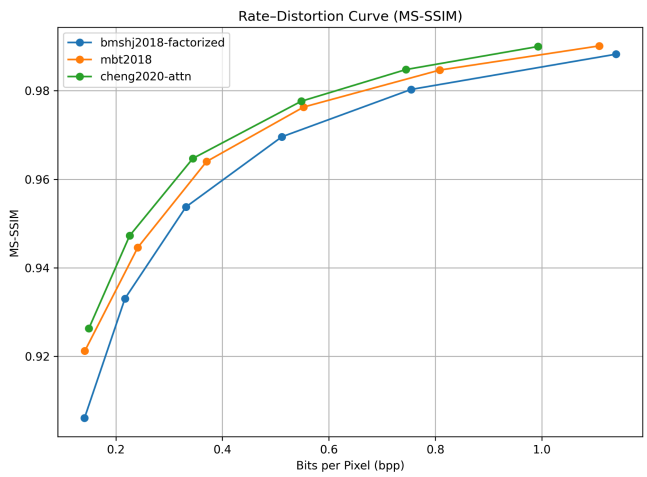

MS-SSIM Καμπύλη

Στην πρώτη καμπύλη, που αφορά MS-SSIM, βλέπουμε ότι το **cheng2020-attn** υπερέχει συστηματικά σε όλα τα bitrates, προσφέροντας την καλύτερη οπτική ποιότητα. Το **mbt2018** ακολουθεί πολύ κοντά, ενώ το **bms 2018-factorized** εμφανίζει χαμηλότερες τιμές, ειδικά στα χαμηλά bitrates. Αυτό δείχνει ότι η χρήση στο cheng 2020 οδηγεί σε καλύτερη διατήρηση οπτικών λεπτομερειών.

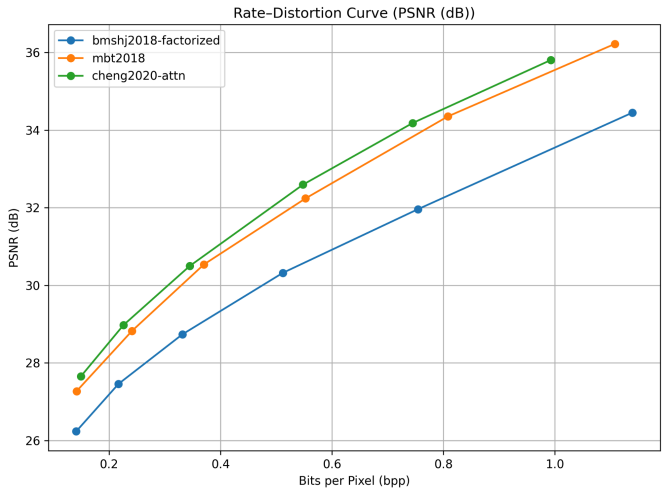

PSNR Καμπύλη

Στο PSNR παρατηρείται αντίστοιχη συμπεριφορά:
το **cheng 2020-attn** παρουσιάζει τις υψηλότερες τιμές, το **mbt2018** ακολουθεί, και το **bms 2018-factorized** βρίσκεται σταθερά χαμηλότερα. Οι διαφορές είναι πιο εμφανείς στα χαμηλά bitrates, όπου η συμπίεση είναι πιο έντονη και τα μοντέλα διαχωρίζονται περισσότερο ως προς την ακρίβεια.

6.Συζήτηση

Όπως παρατηρούμε παραπάνω ο mbsh 2018 factorized υπήρξε το πιο γρήγορο μοντέλο κωδικοποίησης αλλά σε σύγκριση με τα άλλα δυο είχε το μικρότερο rd value. Το cheng 2020 attn απο την άλλη μεριά έχει το μεγαλύτερο χρόνο εκτέλεσης αλλά παράλληλα και την καλύτερη ποιότητα όσον αφορά το rate distortion value μέσα από μετρήσεισ psnr και ms-sim. Τέλος ο bmt2018 ήταν πολύ κοντά σε ποιότητα με τό cheng και είχε ελάχιστα πιο γρήγορη εκτέλεση και ισως θα μπορούσαμε να το χαρακτηρίσουμε ως το sweet spot ανάμεσα στα 3 μοντέλα που μελετήσαμε.

Όσον αφορά τους περιορισμούς που είχαμε στην έρευνά μας, το υλικό υπήρξαν σφαλματα οσον αφορα την μνημη (VRAM 4GB) του λαπτοπ οπου και δεν καταφερε να φορτωθει ολοκληρο το dataset(24 εικονες) συνηθως εμφανιζεται out of memory error στην επεξεργασια της 18ης με 22ης φωτογραφιας

με αποτελεσμα να μην μπορουν να δημιουργηθουν τα plots απο την εντολη κατευθειαν αλλα να πρεπει να τρέξουμε ξεχωριστα το προγραμμα run_plots και να εμφανίζει αποτελεσματα μεχρι την τελευταια εικονα που επεξεργαστηκε.

Επομενως μια μελλοντικη βελτιωση θα μπορουσε σιγουρα να ειναι η καλυτερη διαχειριση της μνημης τη cpu και της καρτας γραφικων ετσι ωστε να μην εμφανιζονται errors ακομη και σε no gpu συστηματα.

Συμπεράσματα

Συνοψίζοντας, η υλοποίηση του project λειτούργησε όπως έπρεπε. Τα δύο scripts εκτέλεσαν σωστά όλη τη διαδικασία (εκτός από το σφάλμα με την μνήμη)από το φόρτωμα των εικόνων και το centercrop μέχρι τη συμπίεση, την καταγραφή των μετρικών και την παραγωγή των RD plots. Η δομή του κώδικα αποδείχθηκε πρακτική και καθαρή, κάνοντας εύκολη την προσθήκη ή αλλαγή μοντέλων. Γενικά, το pipeline έβγαλε σταθερά αποτελέσματα και επιβεβαίωσε ότι η μέθοδος μπορεί να χρησιμοποιηθεί χωρίς προβλήματα για συγκρίσεις ανάμεσα σε διαφορετικούς codecs.

Παραπομπές

CompraisAI https://interdigitalinc.github.io/CompressAI/intro.html

Image Dataset https://r0k.us/graphics/kodak/

7.Σύνοψη

Συνοψίζοντας, η εργασία έδειξε πώς διαφορετικές μέθοδοι συμπίεσης αποδίδουν όταν εξετάζονται με βάση το rate–distortion. Η διαφορά ανάμεσα στην ανθρώπινη θέαση και την αλγοριθμική χρήση φάνηκε ξεκάθαρα, αφού κάθε περίπτωση δίνει έμφαση σε διαφορετικό είδος ποιότητας. Με κοινό πλαίσιο αξιολόγησης και σταθερές μετρικές, προέκυψε μια καθαρή εικόνα των δυνατών και αδύνατων σημείων κάθε προσέγγισης. Τα αποτελέσματα βοηθούν στην επιλογή της κατάλληλης μεθόδου ανάλογα με το πού θα χρησιμοποιηθούν τα δεδομένα.

8. Βιβλιογραφία

[1] https://getstream.io/glossary/video-encoding/

[2] https://www.geeksforgeeks.org/machine-learning/reproducibility-in-machine-learning/

[3] https://www.clearbox.ai/blog/2021-10-26-why-is-reproducibility-in-machine-learning-key/

[4] https://ckaestne.medium.com/versioning-provenance-and-reproducibility-in-production-machine-learning/

[5] https://arxiv.org/abs/2308.07832?utm_source=chatgpt.com

[6] https://en.wikipedia.org/wiki/Ablation_%28artificial_intelligence%29?utm_source=chatgpt.com

[7] California Learning Resource Network

[8] Sullivan, G. & Wiegand, T. (1998). *Rate-distortion optimization for video compression.* IEEE Signal Processing Magazine.

[9] https://link.springer.com/article/10.1007/s10462-023-10662-6?utm_source=chatgpt.com

[10] https://en.wikipedia.org/wiki/Entropy_(information_theory)

[11] https://interdigitalinc.github.io/CompressAI/intro.html

[12] CompressAI, https://interdigitalinc.github.io/CompressAI/intro.html

[13] CompressAI Vision, https://interdigitalinc.github.io/CompressAI-Vision/

[14] Image Dataset https://r0k.us/graphics/kodak/

[15] Ορθογραφική στυλιστική επιμέλεια https://chatgpt.com/chat gpt,https://gemini.google.com/app?hl=el